

LAPORAN TEKNIS KOMPREHENSIF

EDUPREDICT AI: SISTEM DETEKSI DINI RISIKO AKADEMIK SISWA

I. *Project Overview*

Di tengah pesatnya perkembangan digitalisasi pendidikan, tantangan institusi pendidikan tidak lagi hanya berkaitan dengan akses pembelajaran, tetapi juga bagaimana menjaga performa akademik siswa agar tetap stabil dan terhindar dari risiko ketertinggalan akademik. Dalam banyak kasus, penurunan akademik siswa seperti penurunan nilai, prestasi rendah, tidak naik kelas hingga angka putus sekolah (*drop out*) baru disadari setelah hasil evaluasi akhir diperoleh, sehingga proses intervensi menjadi terlambat dan kurang efektif.

Berbagai faktor diketahui memiliki pengaruh terhadap performa akademik siswa, seperti tingkat kehadiran, motivasi belajar, jam belajar, kualitas tidur, keterlibatan orang tua, hingga akses teknologi. Namun, faktor-faktor tersebut sering kali belum dimanfaatkan secara optimal dalam pendekatan berbasis data untuk mendeteksi potensi risiko akademik siswa secara lebih dini.

Berdasarkan permasalahan tersebut, proyek EduPredict AI dikembangkan sebagai sistem analitik pendidikan berbasis data science dan machine learning untuk membantu memahami faktor-faktor yang mempengaruhi performa akademik siswa. Sistem ini dirancang untuk melakukan analisis data pendidikan secara komprehensif, mengidentifikasi faktor risiko akademik, serta memberikan insight yang dapat mendukung pengambilan keputusan di bidang pendidikan.

Melalui proyek ini dilakukan serangkaian tahapan analisis mulai dari *data wrangling*, *exploratory data analysis (EDA)*, *explanatory analysis*, *feature engineering*, hingga *comparative analysis* menggunakan pendekatan statistik. Selain itu, dilakukan pula pembangunan model machine learning untuk memprediksi performa akademik siswa berdasarkan berbagai variabel akademik maupun non-akademik.

II. Tujuan Proyek

Tujuan utama dari proyek EduPredict AI adalah:

1. Menganalisis faktor-faktor yang memengaruhi performa akademik siswa.
2. Mengidentifikasi variabel yang paling berpengaruh terhadap nilai ujian siswa.
3. Melakukan *exploratory* dan *explanatory* analysis untuk memahami pola perilaku belajar siswa.

4. Membangun model *machine learning* untuk memprediksi performa akademik siswa.
5. Melakukan *comparative analysis* menggunakan *Independent T-Test* berdasarkan tingkat kehadiran siswa.
6. Memberikan *insight* berbasis data yang dapat digunakan dalam evaluasi proses pembelajaran.

III. Informasi Dataset

Dataset yang digunakan pada proyek ini adalah [*Student Performance Factors Dataset*](#) yang berisi berbagai informasi terkait aktivitas belajar, kondisi akademik, hingga faktor psikososial dan lingkungan. Dataset terdiri dari kombinasi variabel numerik dan kategorikal yang digunakan untuk menganalisis performa akademik siswa berdasarkan berbagai faktor perilaku dan lingkungan belajar.

Dataset mencakup beberapa variabel penting seperti:

- *Hours Studied*
- *Attendance*
- *Sleep Hours*
- *Previous Scores*
- *Motivation Level*
- *Teacher Quality*
- *Parental Involvement*
- *Internet Access*
- *Exam Score*
- *Tutoring Sessions*
- *Family Income*
- *Peer Influence*
- *Physical Activity*
- *Parental Education Level*

Variabel-variabel tersebut digunakan untuk memahami hubungan antara perilaku belajar siswa dengan hasil akademik yang diperoleh.

IV. Data Wrangling

Tahap data *wrangling* dilakukan untuk memastikan kualitas dataset sebelum digunakan dalam proses analisis dan *modeling*. Tahapan ini mencakup proses data

assessing dan data *cleaning* untuk mengidentifikasi permasalahan data seperti *missing value*, *outlier*, data tidak valid, serta inkonsistensi data lainnya.

V. Data Assessing

Pada tahap data *assessing* dilakukan pemeriksaan awal terhadap struktur dan kualitas dataset. Pemeriksaan dilakukan untuk memahami karakteristik data serta menemukan potensi permasalahan yang dapat mempengaruhi hasil analisis.

Hasil pemeriksaan menunjukkan bahwa dataset terdiri dari 6.607 baris data dengan kombinasi variabel numerik dan kategorikal. Selain itu, ditemukan *missing value* pada beberapa kolom seperti *Teacher_Quality*, *Parental_Education_Level*, dan *Distance_from_Home*. Pemeriksaan juga menemukan adanya nilai tidak valid pada variabel *Exam Score*, yaitu nilai 101, sedangkan rentang nilai ujian seharusnya maksimal 100.

Selain pemeriksaan *missing value*, dilakukan pula pengecekan data duplikat dan deteksi *outlier* menggunakan pendekatan *Interquartile Range* (IQR). Beberapa fitur numerik seperti *Hours_Studied* dan *Tutoring_Sessions* menunjukkan keberadaan *outlier*, namun sebagian besar masih berada pada konteks perilaku belajar yang realistis.

VI. Data Cleaning

Tahap data *cleaning* dilakukan untuk meningkatkan kualitas dataset sebelum digunakan pada proses analisis lebih lanjut. *Missing value* pada variabel kategorikal ditangani menggunakan pendekatan *mode*, sedangkan beberapa variabel numerik ditangani menggunakan median agar distribusi data tetap stabil.

Nilai tidak valid pada *Exam Score* diperbaiki agar sesuai dengan rentang nilai yang valid. Selain itu, dilakukan penanganan *outlier* menggunakan pendekatan *capping/winsorizing* agar data ekstrim tidak terlalu mempengaruhi performa model *machine learning*.

Setelah proses *cleaning* selesai dilakukan, dataset menjadi lebih konsisten dan siap digunakan untuk *exploratory analysis* dan *modeling*.

VII. Feature Engineering

Pada tahap *feature engineering* dilakukan pengembangan fitur tambahan untuk membantu proses analisis dan pemodelan *machine learning*. Salah satu fitur

yang dibuat adalah *Risk_Category* yang digunakan untuk mengelompokkan siswa berdasarkan tingkat risiko akademik.

Kategori risiko dibagi menjadi:

- *Low Risk*
- *Medium Risk*
- *High Risk*

Pembuatan fitur ini bertujuan untuk membantu proses identifikasi siswa yang berpotensi mengalami penurunan performa akademik berdasarkan nilai ujian yang dimiliki.

VIII. *Exploratory Data Analysis (EDA)*

Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik dataset, distribusi variabel, hubungan antar fitur, serta pola yang berpotensi mempengaruhi performa akademik siswa.

Analisis dilakukan menggunakan berbagai visualisasi data seperti histogram, boxplot, dan heatmap korelasi untuk memahami hubungan antara variabel akademik maupun non-akademik terhadap *Exam Score*.

Hasil analisis distribusi menunjukkan bahwa sebagian besar siswa memiliki tingkat kehadiran yang cukup tinggi dengan distribusi yang relatif stabil. Variabel *Hours Studied* menunjukkan bahwa mayoritas siswa memiliki jam belajar pada rentang menengah, sedangkan distribusi *Sleep Hours* menunjukkan bahwa sebagian besar siswa memiliki pola tidur yang masih berada pada rentang normal.

Distribusi *Exam Score* menunjukkan bahwa mayoritas siswa memiliki nilai pada kategori menengah hingga tinggi. Pola distribusi yang relatif mendekati normal menunjukkan bahwa data cukup representatif untuk digunakan dalam proses analisis statistik dan *machine learning*.

Selain analisis distribusi, dilakukan juga analisis korelasi antar variabel numerik menggunakan *correlation heatmap*. Hasil analisis menunjukkan bahwa variabel seperti *Attendance*, *Hours Studied* dan *Previous Score* memiliki hubungan yang cukup kuat terhadap *Exam Score*. Hal tersebut mengindikasikan bahwa konsistensi kehadiran dan intensitas belajar memiliki kontribusi penting terhadap hasil akademik siswa.

IX. *Explanatory Analysis*

Tahap *explanatory analysis* dilakukan untuk menjawab beberapa pertanyaan bisnis utama terkait faktor-faktor yang mempengaruhi performa akademik siswa.

Hasil analisis menunjukkan bahwa siswa dengan tingkat motivasi (*Motivation Level*) yang lebih tinggi cenderung memiliki tingkat kehadiran dan jam belajar yang lebih baik dibandingkan kelompok lainnya. Selain itu, keterlibatan orang tua (*Parental Involvement*) juga menunjukkan hubungan positif terhadap performa akademik siswa, di mana siswa dengan keterlibatan orang tua yang tinggi cenderung memperoleh nilai ujian yang lebih baik.

Analisis terhadap kelompok siswa kategori *high risk* menunjukkan bahwa sebagian besar siswa pada kategori tersebut memiliki kombinasi faktor seperti tingkat kehadiran rendah, motivasi belajar rendah, jam belajar yang lebih sedikit, serta riwayat nilai akademik sebelumnya yang kurang baik. Selain itu, faktor lingkungan seperti kualitas guru dan akses internet juga menunjukkan hubungan terhadap performa akademik siswa.

Secara keseluruhan, hasil *explanatory analysis* menunjukkan bahwa faktor perilaku belajar dan lingkungan akademik memiliki pengaruh yang cukup besar terhadap performa siswa.

X. *Feature Importance Analysis*

Analisis Feature Importance dilakukan untuk mengetahui fitur yang paling berpengaruh terhadap prediksi model *machine learning*.

Hasil analisis menunjukkan bahwa variabel seperti *Attendance*, *Hours Studied* dan *Previous Score* menjadi faktor yang paling dominan dalam mempengaruhi performa akademik siswa. Selain itu, variabel seperti *Motivation Level* dan *Parental Involvement* juga menunjukkan kontribusi terhadap hasil prediksi model.

Hasil ini menunjukkan bahwa perilaku belajar siswa memiliki pengaruh yang cukup besar terhadap performa akademik dibandingkan faktor lainnya.

XI. *Comparative Analysis : Pengaruh Attendance terhadap Exam Score*

Pada tahap ini dilakukan analisis komparatif untuk mengetahui apakah terdapat perbedaan performa akademik siswa berdasarkan tingkat kehadiran (*Attendance*). Data dibagi menjadi dua kelompok, yaitu siswa dengan *Attendance*

rendah dan tinggi berdasarkan nilai median, kemudian dilakukan pengujian menggunakan *Independent T-Test* untuk menganalisis apakah terdapat perbedaan rata-rata *Exam Score* yang signifikan secara statistik antara kedua kelompok tersebut. Hipotesis yang digunakan pada pengujian ini adalah:

- H_0 (*Null Hypothesis*): Tidak terdapat perbedaan rata-rata *Exam Score* antara siswa dengan tingkat *Attendance* rendah dan tinggi.
- H_1 (*Alternative Hypothesis*): Terdapat perbedaan rata-rata *Exam Score* antara siswa dengan tingkat *Attendance* rendah dan tinggi.

Pemeriksaan Asumsi Statistik:

Sebelum melakukan pengujian utama menggunakan *Independent T-Test*, dilakukan terlebih dahulu pemeriksaan asumsi statistik untuk memastikan bahwa data memenuhi syarat penggunaan uji parametrik. Pemeriksaan asumsi meliputi uji normalitas dan uji homogenitas varians.

Hasil uji normalitas menggunakan *Shapiro-Wilk Test* menunjukkan bahwa kedua kelompok memiliki nilai *p-value* kurang dari 0.05 sehingga distribusi data tidak berdistribusi normal. Namun, hasil uji homogenitas menggunakan *Levene Test* menunjukkan bahwa varians kedua kelompok bersifat homogen karena nilai *p-value* lebih besar dari 0.05.

Meskipun asumsi normalitas tidak terpenuhi secara sempurna, pengujian *Independent T-Test* tetap dapat dilakukan karena jumlah sampel yang besar membuat uji ini relatif robust terhadap pelanggaran normalitas berdasarkan prinsip *Central Limit Theorem*.

XII. *Independent T-Test*

Setelah dilakukan pemeriksaan asumsi statistik, pengujian utama menggunakan *Independent T-Test* dilakukan untuk membandingkan rata-rata *Exam Score* antara kelompok siswa dengan *Attendance* rendah dan tinggi.

Hasil pengujian menunjukkan bahwa nilai *p-value* lebih kecil dari tingkat signifikansi 0.05 sehingga keputusan pengujian adalah menolak H_0 . Dengan demikian, terdapat perbedaan yang signifikan secara statistik antara performa akademik siswa dengan tingkat kehadiran rendah dan tinggi.

Kelompok siswa dengan *Attendance* tinggi cenderung memiliki performa akademik yang lebih baik dibandingkan kelompok siswa dengan *Attendance* rendah. Temuan ini menunjukkan bahwa tingkat kehadiran memiliki hubungan yang cukup kuat terhadap hasil akademik siswa.

XIII. *Insight Analysis*

Berdasarkan keseluruhan analisis yang telah dilakukan, ditemukan bahwa faktor perilaku belajar seperti tingkat kehadiran, jam belajar, riwayat nilai sebelumnya hingga motivasi belajar memiliki pengaruh yang cukup besar terhadap performa akademik siswa.

Selain itu, faktor lingkungan seperti keterlibatan orang tua, kualitas guru, dan akses internet juga menunjukkan hubungan terhadap hasil akademik siswa. Analisis ini menunjukkan bahwa pendekatan berbasis data dapat membantu memahami pola performa akademik siswa secara lebih objektif serta mendukung proses identifikasi siswa dengan risiko akademik tinggi.

XIV. *Future Improvement*

Pengembangan yang dapat dilakukan pada proyek berikutnya antara lain:

1. Melakukan *hyperparameter tuning* lebih lanjut untuk mengoptimalkan performa pemodelan.
2. Membuat model berbasis *tree* yang kuat (seperti XGBoost atau Random Forest) sebagai pembanding (*baseline*) untuk menguji apakah model *Deep Learning* memberikan performa yang lebih unggul.
3. Mengeksplorasi rekayasa fitur baru (*feature engineering*) untuk menyaring dan meningkatkan kualitas data *input* sebelum dimasukkan ke dalam model.
4. Menerapkan metode interpretabilitas model agar alasan di balik hasil prediksi kategori risiko siswa dapat dijelaskan secara transparan kepada pihak sekolah.
5. Mengimplementasikan eksperimen *A/B Testing* nyata menggunakan fitur *reminder* belajar pada aplikasi EduPredict.

XV. *Kesimpulan*

Proyek EduPredict AI berhasil melakukan analisis komprehensif terhadap faktor-faktor yang memengaruhi performa akademik siswa menggunakan pendekatan *data science* dan *machine learning*.

Hasil analisis menunjukkan bahwa variabel seperti *Attendance*, *Hours Studied*, dan *Previous Scores* merupakan faktor yang paling berpengaruh terhadap performa

akademik siswa. Selain itu, faktor perilaku belajar dan lingkungan akademik juga menunjukkan kontribusi terhadap hasil akademik siswa.

Melalui *exploratory analysis*, *explanatory analysis*, *feature importance analysis*, dan *comparative analysis* menggunakan *Independent T-Test*, proyek ini berhasil memberikan *insight* berbasis data yang relevan dalam memahami pola performa akademik siswa serta mendukung proses pengambilan keputusan di bidang pendidikan.